

ENTREGA FINAL

# Ecosistema de Automatización IA Autónomo para Negocios

Caso de uso: cotizaciones logísticas automatizadas con n8n, Airtable, Gmail y GPT-OSS 120B vía Groq

Proyecto

Ecosistema IA - Cotizaciones Logísticas Automatizadas. Workflow activo, con validación, memoria persistente, Human-in-the-Loop, rutas de error y control de tarifa no disponible.

| CAPA              | TECNOLOGÍA                   | ROL                                      |
|-------------------|------------------------------|------------------------------------------|
| Orquestación      | n8n                          | Trigger, lógica, ramas y ejecución       |
| Memoria / tarifas | Airtable                     | Rutas, estados, trazabilidad y dashboard |
| IA                | openai/gpt-oss-120b vía Groq | Extracción estructurada y redacción      |
| Canal             | Gmail                        | Entrada, HITL y respuesta al cliente     |

Federico Jorda

Supervisor de ruteo

12 de agosto de 2026

## 01 Resumen ejecutivo

Automatización autónoma con controles humanos antes de acciones críticas.

El sistema recibe solicitudes de cotización por Gmail, utiliza IA para extraer datos logísticos en JSON, valida los campos obligatorios y consulta Airtable como fuente de verdad para rutas, tipos de carga, precios y tiempos estimados.

Cuando existe una tarifa compatible, una segunda etapa de IA redacta una propuesta comercial en HTML utilizando exclusivamente datos del correo y Airtable. La propuesta se registra y queda detenida en un punto Human-in-the-Loop (HITL): una persona debe aprobarla o rechazarla antes de que Gmail contacte al cliente.

El ecosistema también contempla datos incompletos, errores de IA y combinaciones sin tarifa. Cada caso se registra con un estado específico, lo que permite auditoría, métricas y seguimiento desde un Dashboard de Airtable.

### Resultado

El workflow exportado contiene 21 nodos, se encuentra activo y cubre proceso principal, rechazo humano, datos incompletos, error de extracción IA y tarifa no encontrada.

- Automatización end-to-end desde correo entrante hasta respuesta al cliente.
- Memoria persistente en Airtable y separación entre tabla de tarifas y tabla transaccional.
- IA con límites de salida: 300 tokens para extracción y 1.000 para generación.
- Control HITL obligatorio antes del envío de una cotización generada por IA.
- Dashboard de control con métricas operativas y tasa de error.

## 02 Arquitectura y mapa del ecosistema

Flujo principal y rutas alternativas de resiliencia.




Figura 1. Arquitectura lógica del workflow. Los nodos 03 y 08 son los modelos Groq conectados a los agentes 02 y 07.

### Principio de diseño

Airtable funciona como memoria y fuente de verdad comercial; la IA interpreta y redacta, pero no define precios. El envío al cliente queda condicionado por una aprobación humana.

03 Lógica operativa y decisiones

Cómo se comporta el sistema ante cada tipo de solicitud.

| CASO                     | CONDICIÓN                                                       | ruta / resultado                                         |
|--------------------------|-----------------------------------------------------------------|----------------------------------------------------------|
| Datos completos + tarifa | origen, destino, peso y tipo_carga presentes; tarifa encontrada | Genera propuesta → registra → HITL → aprobado/rechazado. |
| Datos incompletos        | Falta al menos un campo obligatorio                             | Estado Incompleto → Gmail solicita datos faltantes.      |
| Sin tarifa               | Datos válidos pero búsqueda Airtable devuelve 0 registros       | Estado Sin tarifa → Gmail informa que requiere revisión. |
| Error IA extracción      | El agente 02 falla                                              | Salida de error → Airtable registra Estado Error.        |
| Aprobado                 | HITL devuelve approved=true                                     | Marca aprobado → envía al cliente → Estado Enviado.      |
| Rechazado                | HITL devuelve approved=false                                    | Estado Rechazado por Humano; no se envía al cliente.     |

Control anti-silencio

El nodo 06 usa Always Output Data. Si no existe coincidencia de tarifa, el IF 06B recibe un item vacío y deriva explícitamente a la rama Sin tarifa, evitando que el workflow termine “exitosamente” sin respuesta.

Campos obligatorios validados

- origen (String, no vacío)
- destino (String, no vacío)
- peso\_kg (Number, no vacío)
- tipo\_carga (String, no vacío; normalizado a General, Frágil, Refrigerada o Peligrosa)

04 Modelo de datos y memoria

Airtable separa configuración comercial de trazabilidad transaccional.

Tabla Rutas\_Tarifas

| CAMPO           | TIPO          | función                                    |
|-----------------|---------------|--------------------------------------------|
| Origen          | Texto         | Punto de partida                           |
| Destino         | Texto         | Punto de llegada                           |
| Tipo de carga   | Single select | General / Frágil / Refrigerada / Peligrosa |
| Precio base     | Moneda        | Tarifa usada por la IA sin modificar       |
| Tiempo estimado | Texto         | Ventana estimada de tránsito               |

| CAMPO        | TIPO             | FUNCIÓN                             |
|--------------|------------------|-------------------------------------|
| Cotizaciones | Link a registros | Relación con cotizaciones generadas |

## Tabla Cotizaciones

| GRUPO     | CAMPOS PRINCIPALES                                               |
|-----------|------------------------------------------------------------------|
| Identidad | Id, Cliente Email, Cliente, Message-ID Original, Asunto Original |
| Solicitud | Ruta, Peso (kg), Mensaje Original                                |
| IA        | Texto Generado IA, Detalle Error                                 |
| Control   | Estado, Aprobado por Humano, Timestamp, Resume Webhook URL       |
| Métrica   | Indicador Error (fórmula: 1 si Estado = Error; 0 en otro caso)   |

### Ejemplo de tarifa real

CABA → Buenos Aires / Frágil: precio base \$35.000 y tiempo estimado 24-48hs. El workflow consulta esta tabla por origen + destino + tipo de carga.

## 05 Estructuras JSON y contratos de transferencia

Los datos se normalizan antes de avanzar a decisiones comerciales.

### Salida del agente de extracción

```
{
  "origen": "CABA",
  "destino": "Buenos Aires",
  "tipo_carga": "Frágil",
  "peso_kg": 2000,
  "urgencia": null
}
```

### Datos de tarifa utilizados por la generación

```
{
  "origen": "CABA",
  "destino": "Buenos Aires",
  "tipo_carga": "Frágil",
  "precio_base": 35000,
  "tiempo_estimado": "24-48hs"
}
```

### Respuesta HITL esperada

```
{
  "data": {
    "approved": true
  }
}
```

}

Regla anti-alucinación

El prompt de generación prohíbe inventar precios, rutas, pesos, tiempos, servicios, descuentos, condiciones comerciales y datos de contacto. El HTML se construye sólo con información del email y Airtable.

06 Diseño de IA y control de tokens

Dos tareas separadas, con prompts y presupuestos distintos.

| ETAPA      | MODELO                       | LÍMITE       | PROPÓSITO                                           |
|------------|------------------------------|--------------|-----------------------------------------------------|
| Extracción | openai/gpt-oss-120b vía Groq | 300 tokens   | Convertir email no estructurado a JSON normalizado. |
| Generación | openai/gpt-oss-120b vía Groq | 1.000 tokens | Redactar HTML profesional usando datos validados.   |

- El modelo es de OpenAI (open-weight) pero la inferencia del workflow se ejecuta mediante el nodo Groq; por lo tanto, el costo operativo del flujo corresponde al proveedor Groq.
- La extracción devuelve sólo JSON y normaliza sinónimos de tipo de carga.
- La generación responde con HTML crudo, sin Markdown y con una firma fija autorizada.
- Los límites de tokens reducen costo y riesgo de respuestas innecesariamente largas.

07 Matriz de costos y elección de modelo

Comparación de costo variable de inferencia para un escenario homogéneo.

Supuesto de cálculo

1.000 cotizaciones completas; por cotización se estiman 1.300 tokens de entrada y 500 tokens de salida acumulados entre ambas etapas. Los valores sirven para comparar proveedores; el consumo real depende del largo de cada email y respuesta.

| PROVEEDOR / MODELO           | INPUT / 1M | OUTPUT / 1M | USD / 1.000 | LECTURA                                                      |
|------------------------------|------------|-------------|-------------|--------------------------------------------------------------|
| Groq · GPT-OSS 120B          | \$0,15     | \$0,60      | \$0,50      | Elegido: bajo costo, velocidad y modelo actual del workflow. |
| OpenAI · GPT-5 mini          | \$0,25     | \$2,00      | \$1,33      | Alternativa económica en API OpenAI.                         |
| Anthropic · Claude Haiku 3.5 | \$0,80     | \$4,00      | \$3,04      | Más caro para este patrón de tokens.                         |
| Cohere · Command R           | \$0,15     | \$0,60      | \$0,50      | Costo comparable; alternativa de proveedor.                  |

| PROVEEDOR / MODELO                                                                                                                                                                                                                                                                                                            | INPUT / 1M | OUTPUT / 1M | USD / 1.000 | LECTURA |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|-------------|-------------|---------|
| <b>Decisión</b><br><br>GPT-OSS 120B vía Groq ofrece el mejor equilibrio para esta implementación. En el supuesto utilizado, cuesta aproximadamente USD 0,50 por cada 1.000 cotizaciones en inferencia LLM. Groq ofrece además Batch con 50% de descuento, pero no es apropiado para el tramo interactivo/HITL de tiempo real. |            |             |             |         |

Fuentes de precios consultadas (agosto 2026): Groq Pricing; OpenAI “Introducing GPT-5 for developers”; Anthropic Pricing; Cohere Command R documentation. Precios en USD por 1M tokens.

08 Seguridad, resiliencia y gobierno

Controles técnicos y operativos para evitar automatizaciones peligrosas o silenciosas.

| CONTROL          | IMPLEMENTACIÓN                                                         | RIESGO MITIGADO                              |
|------------------|------------------------------------------------------------------------|----------------------------------------------|
| HITL             | Gmail Send and Wait + IF booleano                                      | Evita contacto comercial no autorizado.      |
| Fuente de verdad | Precios y tiempos provienen de Airtable                                | Reduce alucinación de datos comerciales.     |
| Validación       | IF tipado de 4 campos obligatorios                                     | Evita cotizar con información incompleta.    |
| No tarifa        | Always Output Data + IF 06B                                            | Evita finalización silenciosa sin respuesta. |
| Error IA         | continueErrorOutput en agente de extracción                            | Registra fallos de IA en memoria.            |
| Anti-loop        | Trigger filtra asunto, no leídos y excluye remitente de automatización | Reduce ciclos de auto-respuesta.             |
| Credenciales     | Referencias de credenciales de n8n; sin API keys en prompts            | Separa secretos del contenido de negocio.    |
| Observabilidad   | Estados + Indicador Error + dashboard                                  | Permite seguimiento operativo.               |

Punto de mejora productivo

La dirección del aprobador y el filtro anti-loop están definidos como constantes de despliegue en la demo. Para producción conviene moverlos a variables de entorno/configuración. También puede agregarse manejo de error al parser JSON y al agente de generación.

09 Dashboard y observabilidad

Estado actual de la memoria transaccional y evidencia de la interfaz.




Figura 2. Snapshot final de Airtable: 47 registros y tasa de error del 2%.

| MÉTRICA              | VALOR |
|----------------------|-------|
| Total cotizaciones   | 47    |
| Procesado por IA     | 16    |
| Enviado              | 11    |
| Incompleto           | 11    |
| Rechazado por Humano | 6     |
| Sin tarifa           | 2     |
| Error                | 1     |
| Tasa de error        | 2%    |



Cotizaciones

Monitoreo operativo del flujo automatizado de cotizaciones: estados, aprobaciones humanas y tasa de errores.




Figura 3. Dashboard final de Airtable: 47 cotizaciones, estados y aprobación humana.

Publicación


El Dashboard y las vistas públicas de Airtable se encuentran publicados en modo de solo lectura. El README del repositorio incluye el Dashboard operativo, la memoria de Cotizaciones y la fuente de verdad de Rutas y Tarifas.

10 Pruebas y evidencias

Cobertura funcional visible en datos y configuración.

| PRUEBA                  | RESULTADO ESPERADO                         | EVIDENCIA ACTUAL                              |
|-------------------------|--------------------------------------------|-----------------------------------------------|
| T01 Completa + aprobar  | Enviar cotización y marcar Enviado         | 11 registros Enviado en Airtable.             |
| T02 Completa + rechazar | No contactar cliente; marcar rechazo       | 6 registros Rechazado por Humano.             |
| T03 Datos faltantes     | Registrar Incompleto y solicitar faltantes | 11 registros Incompleto.                      |
| T04 Sin tarifa          | Registrar Sin tarifa y avisar al cliente   | 2 registros Sin tarifa; rama 06B -> 19 -> 20. |
| T05 Error IA            | Registrar Estado Error                     | 1 registro Error; manejo de error verificado. |
| T06 Prompt / tokens     | JSON + HTML controlado; límites aplicados  | 300 tokens extracción / 1.000 generación.     |

Evidencia visual - rama de tarifa no encontrada



IF 06B entre búsqueda de tarifa y generación.

### Values to Send

🗑

Cliente Email

fx

`{{ $('01 - Gmail Trigger - Nueva Cotización').item.json.From }}`

🔗

"Nicolás Godirio" <nicolasgodirio@gmail.com>

🗑

Peso (kg)

fx

`{{ $('04 - Parsear JSON de IA').item.json.peso_kg }}`

🔗

🗑

Estado

Sin tarifa

▼

🗑

☐ Aprobado por Humano

🗑

Message-ID Original

fx

`{{ $('01 - Gmail Trigger - Nueva Cotización').item.json.threadId }}`

🔗

19ff397936e78555

🗑

Asunto Original

fx

`{{ $('01 - Gmail Trigger - Nueva Cotización').item.json.Subject }}`

🔗

Re: automatizar ai

🗑

Detalle Error

`{{ 'No se encontró tarifa para: ' +`

`$('04 - Parsear JSON de IA').item.json.`

`origen + ' → ' + $('04 - Parsear JSON de IA').item.json.destino`

11 Estructura de entrega y trazabilidad con la rúbrica

Organización recomendada del repositorio público.

```
README.md
/docs/Entrega_Final_Ecosistema_IA.pdf
/workflow/Ecosistema_IA_Cotizaciones_Logisticas.json
/evidencias/
  workflow.png
  hitl_aprobacion.png
  dashboard.png
  caso_incompleto.png
  caso_sin_tarifa.png
```

| CRITERIO DE RÚBRICA     | COBERTURA EN ESTA ENTREGA                                           |
|-------------------------|---------------------------------------------------------------------|
| Arquitectura / mapa     | Secciones 2 y 3 + diagrama de flujo y ramas.                        |
| Datos + JSON schemas    | Secciones 4 y 5.                                                    |
| Matriz de costos        | Sección 7 con comparación por 1M tokens y por 1.000 cotizaciones.   |
| Seguridad / resiliencia | Sección 8: HITL, validaciones, errores, anti-loop y observabilidad. |
| Dashboard               | Sección 9: estructura, snapshot, KPIs y evidencia visual.           |

Estado final de publicación

README actualizado con los tres enlaces públicos de Airtable y el video demostrativo en Google Drive; JSON final reexportado con la base "Cotizaciones Logísticas IA"; capturas finales de workflow, HITL y Dashboard incorporadas. Antes de entregar: verificar repositorio, Airtable y video en incógnito y confirmar que no se publiquen secretos/API keys.

Conclusión

El ecosistema implementa automatización real, memoria persistente, IA con restricciones, Human-in-the-Loop y rutas de resiliencia. La arquitectura es reproducible, auditable y adecuada para demostrar un caso de negocio autónomo con control humano sobre acciones críticas.